Integração de Dados

Licenciatura em Engenharia Informática: 2º ano - 2º semestre 2024/205

Trabalho Prático

Integração de Dados com XML

***Nota prévia**: O enunciado é propositadamente vago, genérico e incompleto em alguns pontos. O que se pretende é que os alunos avaliem as várias opções existentes e escolham a que considerarem mais apropriada para cada uma das situações com que se depararem. Todas as escolhas devem ser referidas e devidamente justificadas no relatório a entregar.*

1. Objetivos

Com este trabalho pretende-se criar um programa em Java composto por vários Wrappers que obtenham dados de fontes heterogéneas, distribuídas e autónomas e possibilitem ao utilizador a visualização dos dados de forma integrada.
O utilizador terá ainda a possibilidade de fazer pesquisas, acrescentar dados que respeitem os esquemas adotados e gerar ficheiros com informação selecionada.
Para a realização deste trabalho deve usar a Linguagem Java, Expressões regulares e os APIs JDOM2 e SAXON estudados nas aulas práticas.

2. Resultados da Aprendizagem

Com este trabalho prático pretende-se que se adquiram as seguintes competências:

- Saber analisar uma situação típica de Integração de Dados e apresentar propostas válidas para um modelo de integração funcional, eficaz e correto;
- Capacidade de criação e manipulação de XML
- Utilização de expressões regulares
- Capacidade de realização de pesquisa de informação em ficheiros XML usando XPath e/ou XQuery
- Capacidade de efetuar transformações de ficheiros XML usando XSLT e/ou XQuery
- Capacidade de efetuar validação de ficheiros XML usando DTD e/ou XSD

3. Descrição do Trabalho

O objetivo do trabalho é criar uma aplicação de integração de dados que apresente uma visão unificada de informações relativas a diferentes países.
A informação deverá ser extraída dos dois sites a seguir apresentados, tratada e integrada em ficheiro(s) XML.
Fontes de dados

- https://pt.wikipedia.org/wiki/
- https://pt.db-city.com/

No site wikipedia:

```
HttpRequestFunctions.httpRequest1("https://pt.wikipedia.org/wiki/", pais, pais+"_wiki.html");
```

>> Depois, aplicar os Wrappers no ficheiro criado para extrair os dados

No site DBCity:

```
HttpRequestFunctions.httpRequest1("https://pt.db-city.com/", país, pais + "_dbcity.html");
```

>> Depois, aplicar os Wrappers no ficheiro criado para extrair os dados.

As fontes de dados são heterogéneas, autónomas e distribuídas e contêm informação relevante sobre o tema do trabalho.

O objetivo do trabalho prático consiste em efetuar **integração de dados** provenientes destas duas fontes de dados e construir um modelo global de dados usando XML onde toda a informação pesquisada seja organizada em elementos/atributos, usando a hierarquia decidida pelos alunos como a mais correta para executar as tarefas propostas.

A informação de cada país que se pretende encontrar usando os dois sites é a seguinte (os alunos devem incluir informação adicional que achem relevante):

- Nome da país
- Capital do país
- Continente
- Link para a imagem da bandeira do pais
- Língua(s) oficial(ais) do país
- Área do país (valor numérico em km^2)
- Nº de habitantes da país
- Densidade populacional do país (nº de habitantes por km^2)
- Presidente/Chefe de estado
- Lista de Religiões
- Lista de cidades importantes
- Lista de países de fronteira
- Nº de casos COVID registados

NOTA: Os **valores numéricos** devem ser tratados para poderem ser corretamente manipulados por pesquisas XPATH/XQUERY. Este tratamento pode passar por eliminar o separador dos milhares, eliminar espaços em branco, colocar o separador decimal como . (ponto) em vez de , (virgula), etc.

EXEMPLO (do site DBcity):

Número de habitantes China 1.395.380.000 habitantes (2018)

>> O Wrapper deve devolver: 1395380000 (eliminar o separador dos milhares) e posteriormente colocado no XML: `<habitantes>1395380000</habitantes>`

Por exemplo, a aplicação de todos os Wrappers com a introdução de Portugal deve devolver informação relevante:

```
Capital: Lisboa
Continente: Europa
Bandeira: https://dwpt1kkww6vki.cloudfront.net/img/drapeau/120/170.png
Linguas oficiais: [Português, Mirandese]
Área: 92391
População: 10287000
Densidade: 111.3
Chefe estado: Marcelo Rebelo de Sousa
Religiões: [Cristianismo, Protestantismo]
Cidades importantes: [Lisboa (Capital), Sintra, Vila Nova de Gaia, Porto e Cascais]
Paises fronteira: [Espanha]
Casos covid: 822314
```

- Os alunos devem analisar as diferentes fontes de dados e apresentar um estudo das mesmas, decidindo e justificando onde vão retirar a informação. Obrigatoriamente, devem ser usadas **as duas** fontes de dados fornecidas.

O esquema a adotar na vista unificada deve ser decidido pelos alunos e validado usando o XSD e o DTD apropriado. Depois de realizado o processo de integração dos dados, o utilizador poderá fazer pesquisas sobre a vista unificada.

4. Tarefas a Realizar

Encontram-se em seguida as **tarefas principais** a desenvolver neste trabalho prático. As descrições são genéricas e os exemplos apresentados servem apenas para uma melhor compreensão do que é pretendido. Os alunos devem ser criativos e apresentar uma solução integradora completa e funcional que permita efetuar uma grande diversidade de pesquisas.

4.1. Analisar as fontes de dados (S)

A primeira parte do trabalho consiste em analisar as fontes de dados e verificar onde pode ser encontrada a informação sobre os países.
Todas as situações de exceção devem avaliadas e as decisões tomadas devem ser justificadas no relatório. Por exemplo:

- Caso encontre informação duplicada nas várias fontes
- Se um país não for encontrada
- Se algum dos atributos pedido não existir para algum país
- ...

4.2. Definir o esquema global (G)

Defina um modelo global para a recolha dos dados. Este modelo deve ser baseado num modelo XML com a estrutura hierárquica adequada ao problema proposto. Isto é, o aluno deve analisar qual a estrutura do(s) ficheiro(s) que considera mais adequada no que se refere ao nível de ramificação e à escolha de elementos ou atributos para guardar os dados. O esquema a adotar na vista unificada decidido pelos alunos deve ser sempre validado usando o XSD e o DTD apropriado.

4.3. Implementar Wrappers (Mapeamentos M)

Implementar os *Wrappers* que permitam obter a informação relevante de cada fonte de dados. Estes *Wrappers* devem ser implementados usando expressões regulares. No relatório deve ser descrito detalhadamente cada um dos wrappers, indicando que informação é retirada por cada um deles da fonte de dados em que cada um opera. Para cada atributo a encontrar, deve(m) ser selecionada(s) a(s) fonte(s) de dado(s) relevante(s). No caso de encontrar inconsistências ou conflitos os alunos terão de propor uma solução.

Para saber como implementar os Wrappers deve analisar a estrutura das páginas HTML onde vai procurar a informação.
Use a função *httpRequest* dada nas aulas práticas para aceder às páginas e gravá-las em disco.
O número e a estrutura dos wrappers depende da forma e da quantidade de informação que se quer encontrar e deve ser analisada pelos estudantes.

IMPORTANTE: para evitar o bloqueio do site db-city devido a httpRequests consecutivos, na fase de teste, os alunos NÃO DEVEM fazer httprequest, mas devem usar os sources das páginas dos países disponibilizados no Moodle na pasta "sources"

4.4. GERAR / MANIPULAR FICHEIRO XML: ACRESCENTAR, EDITAR E ELIMINAR DADOS

Depois de implementados os *wrappers*, os dados devem ser guardados em ficheiro(s) XML usando o modelo escolhido. Deverá ser possível

- Adicionar um novo país, desde que este não exista no ficheiro XML.
- Se o ficheiro não existir ainda, deve ser criado com a inserção do primeiro país.
- Eliminar um país (usar nome do país como palavra de pesquisa).
- Editar/alterar alguns atributos do ficheiro XML (área, capital, ...)

4.5. VALIDAR O MODELO G

Os ficheiros do modelo **G** devem ser validados usando os XSD/DTD escolhidos.
Esta tarefa deve ser feita usando o API JDOM2 dado nas aulas práticas.

4.6. FAZER PESQUISAS XPATH

Permitir ao utilizador efetuar diferentes pesquisas sobre o modelo XML:

- Pesquisar pelo nome do país e mostrar a informação relevante (capital, área, nº de habitantes, ...)
- Pesquisar cidades importantes de um dado país
- Pesquisar países com número de habitantes superior a um valor introduzido
- Pesquisar países com uma determinada religião
- Pesquisar todas as capitais existentes no ficheiro
- Mostrar países com casos covid entre um valor mínimo e um valor máximo
- (outras pesquisas propostas pelos alunos terão cotação adicional)

4.7 GERAR FICHEIROS DE OUTPUT (XSLT/XQUERY)

O programa deve possibilitar ao utilizador gerar ficheiros de resultados. Estes ficheiros devem ser transformações do modelo XML da vista global.
quatro transformações **obrigatórias**:

- Gerar ficheiro HTML de fotos das bandeiras dos países inseridos no ficheiro (sem repetições)
- Gerar ficheiro TXT que mostre a listagem das cidades importantes de um dado país
- Gerar um ficheiro XML com os 5 países mais populosas
- Pedir ao utilizador o nome de um país e gerar um ficheiro HTML que mostre uma lista dos países fronteira

Os alunos devem propor no mínimo **mais três** transformações adicionais. Devem implementar as transformações usando as duas tecnologias dadas nas aulas - XSLT e XQuery – optando pela que for mais adequada em cada situação.

4.8. *INTERFACE GRÁFICO*

A aplicação deve ter uma interface amigável e intuitiva, disponibilizando ao utilizador um conjunto de opções, por exemplo, sugere-se a seguinte estrutura:

- Opções gerais
  - Ver conteúdo do ficheiro XML
  - Validar modelo de dados (DTD e XSD)
  - Sair da aplicação
- Alterar dados do modelo XML (efetue sempre a validação do modelo em cada uma das opções)
  - Eliminar uma país do ficheiro (usar nome como palavra de pesquisa)
  - Acrescentar um país que não exista no ficheiro
    - pedir <pais> e usar os Wrappers para obter os dados da web
  - Alterar alguns atributos de um país
- Efetuar Pesquisas XPATH
  - ...
- Gerar Outputs XSLT / XQUERY
  - ...

5. NORMAS PARA REALIZAÇÃO DO TRABALHO

O trabalho deverá ser realizado **individualmente ou em grupos de dois alunos**.

O trabalho vale 6 valores e é necessário um mínimo de 35% para aprovação na Unidade Curricular.

O trabalho final deve ser entregue até **18 de Maio de 2025** às 23h59 GMT.
>>>>>> DATA ÚNICA DE ENTREGA PARA TODAS AS ÉPOCAS DE EXAME <<<<<<

A entrega dos trabalhos deverá ser feita usando a plataforma Moodle. Deve ser submetido um ficheiro compactado cujo nome deve conter a identificação dos elementos do grupo de trabalho:
Por exemplo: **a22222_AnaMatos_a33333_RuiMelo_P1.zip**

O ficheiro deve conter o projeto Java com a implementação da aplicação e todos os ficheiros DTD, XSD, XSLT, XQuery, etc que foram implementados.

Os trabalhos serão sujeitos a **defesa obrigatória** nas aulas da semana 19 a 23 de Maio.

6. CRITÉRIOS DE AVALIAÇÃO

O trabalho vale **6 valores** na nota final da Unidade Curricular. Para aprovação na UC é necessário ter um mínimo de 35% neste trabalho.

O trabalho será avaliado segundo os seguintes critérios:

- Qualidade e correção na implementação das tarefas solicitadas
  - Wrappers: 30%
  - XML: 20%
  - DTD/XSD: 5%
  - Xpath: 5%
  - Xquery: 10%
  - XSLT: 10%
- Funcionalidade do interface: 10%
- Relatório e defesa: 10%
- **Uma defesa fraca implica uma penalização nas cotações anteriores.**